

项目计划书：RetroAir —— 基于多源数据的历史 PM2.5 回顾性推断

选题类别：C 类 —— 端到端应用系统开发

团队成员：关镜文、黄一和、黄弋涵、夏浩博

提交日期：2026 年 5 月

一、项目目标

本项目旨在构建一个**完整的端到端 PM2.5 回顾性推断系统**。核心思路是：利用地面监测站已有的历史 PM2.5 观测数据作为标签，结合该位置的卫星气溶胶光学厚度（AOD）数据和气象数据，训练回归模型，从而推断**无监测站覆盖地区**的历史 PM2.5 浓度^{[3][6]}。

最终交付一个可交互的 Web 应用：用户在界面上选择任意经纬度和历史日期，系统自动获取该位置的气象与 AOD 数据，通过训练好的模型给出 PM2.5 预测值和空气质量等级^{[4][5]}。

二、项目背景与动机

2.1 为什么需要这个系统？

PM2.5 是最主要的空气污染物之一，对呼吸系统和心血管健康有显著危害^[1]。然而，地面空气质量监测站的建设与维护成本极高——中国国控城市空气站点在“十三五”期间为 1,436 个，“十四五”优化为 1,734 个，主要覆盖地级及以上城市区域^[2]，广大农村和中小城市几乎无覆盖。对于流行病学研究和环境健康评估而言，**历史 PM2.5 的空间缺失**是一个长期未解决的问题^[3]。

2.2 技术可行性

近年来，卫星遥感技术提供了全球覆盖的气溶胶数据。欧洲中期天气预报中心（ECMWF）旗下的 CAMS EAC4 再分析数据集提供了 2003 年至今的全球气溶胶光学厚度（AOD），包含总 AOD 及各组分（沙尘、硫酸盐、黑碳、有机物、海盐）的浓度估计^[4]。同时，NASA POWER 提供了免费的全球历史气象数据^[5]。

已有研究表明，AOD 与地面 PM2.5 之间存在统计相关性，且气象条件（温度、湿度、风速等）显著影响气溶胶的扩散与转化^{[6][7]}。因此，**利用 AOD + 气象作为特征、监测站 PM2.5 作为标签来训练回归模型**，在技术上是可行且有文献支持的^[8]。

三、数据来源与特征设计

3.1 数据来源

数据	来源	覆盖	说明
PM2.5 标签	AKShare 真气网 API	中国主要城市 2018-2025	国控监测站逐日浓度

数据	来源	覆盖	说明
气象数据	NASA POWER API	全球，逐日	温度、湿度、风速、风向、气压、降水、云量
气溶胶 AOD	CAMS EAC4 (Copernicus ADS)	全球 0.75°，逐日	9 个通道：总 AOD + 各组分 AOD

3.2 特征设计

初步计划使用以下特征组进行模型训练：

特征组	列数	变量
AOD	9	总 AOD、各组分 AOD（沙尘、硫酸盐、黑碳、有机物、海盐）及气溶胶波长指数
气象	7	温度、相对湿度、风速、风向、气压、降水、云量
时间	1	年内第几天，捕捉季节性周期

同时，我们也计划探索 OSM 空间特征和 MODIS RGB 反射率特征作为潜在补充维度。若消融实验证明其有效，则加入最终模型；否则将放弃。

3.3 数据管道设计

计划按以下流程构建自动化数据管道（使用 Python 脚本串联）：

- AQI 获取**：调用 AKShare API 逐城市逐日抓取监测站数据，关联公开站点坐标清单
- 气象获取**：根据站点经纬度批量调用 NASA POWER API
- AOD 提取**：从 CAMS EAC4 NetCDF 文件中按经纬度和日期提取 AOD 值
- 合并**：以（城市，站点名称，日期）为键做 inner join
- 多城聚合**：合并各城市的独立数据集为全国多城训练集

四、模型方案与评估策略

4.1 模型选择

计划实现并对比 **5-6 种回归算法**，覆盖树模型与深度学习两大类：

- 树模型**：LightGBM、XGBoost、CatBoost
- 深度学习**：ResMLP、DCN-V2、FT-Transformer

4.2 评估策略

- 数据切分**：随机切分（而非时间切分），因本任务为空间插值而非时间预测
- 评估指标**： R^2 、RMSE、MAE、SMAPE、MAPE、Pearson 相关系数
- 消融实验**：对气象、AOD、OSM、RGB 四个特征维度做排列组合实验（共 15 组），确定最优特征组合

4.3 模型部署

训练完成后，将最优模型权重、特征定标器（StandardScaler）保存为文件，供 Web 应用加载使用。

五、Web 应用设计

计划使用 Streamlit 框架构建交互式 Web 界面：

- **地图交互**：用户点击地图或拖动标记选择位置
- **城市快捷选择**：预设国内外主要城市坐标
- **日期选择**：支持 2018 年至 CAMS 最新可用年份
- **一键预测**：点击按钮后，系统自动获取实时气象数据 + 历史 AOD 数据 → 推理 → 展示 PM2.5 浓度和空气质量等级
- **特征展示**：可展开查看具体的气象和 AOD 数值

六、团队分工

姓名	角色	负责内容
关镜文	数据工程师	地面监测站 PM2.5 数据获取与清洗；气象数据、CAMS AOD气溶胶数据批量下载与校验；多源数据合并与去重；整体数据管道编排
黄一和	算法工程师	CAMS AOD 气溶胶数据提取与特征工程；深度神经网络模型的设计、实现与训练；PyTorch 训练框架搭建
夏浩博	评估与优化	树模型的实现与超参调优；特征维度消融实验设计与执行；多算法统一对比框架与结果可视化
黄弋涵	工程与展示	数据加载、标准化与评估指标模块；Web 推理应用的前后端开发；模型部署与推理管线；项目文档撰写与演示 PPT 制作

七、时间规划

阶段	周次	里程碑
需求分析与技术调研	第 13 周	确定选题 C；评估各数据源的可行性与覆盖范围；搭建项目骨架与 Git 仓库
数据管道开发	第 14 周	完成 AQI/气象/AOD 三源数据获取脚本；实现数据合并与清洗；构建第一批城市数据集
模型开发与消融实验	第 15-16 周	实现全部 6 种模型；完成特征维度消融实验，确定最优特征组合；选出最佳模型
Web 应用开发	第 16-17 周	构建 Streamlit 交互界面；集成推理管线；前后端联调测试
项目报告与演示准备	第 17-18 周	撰写项目报告（学术论文格式）；制作 PPT；录制系统演示；整理代码仓库

八、预期成果

- 1. 一套可自动化运行的数据管道，支持按城市和年份构建训练数据集
- 2. 一个经过严格消融实验验证的最优模型，在测试集上预期 $R^2 > 0.85$ （同类研究已在中国尺度 PM2.5 估算中达到约 0.85 的交叉验证 R^2 ）^[8]
- 3. 一个可公开访问的 Web 推理应用，全球任意位置的历史 PM2.5 推断
- 4. 一份完整的技术报告，包含方法、实验、分析与结论

九、风险与应对

风险	应对措施
CAMS AOD 数据延迟（通常滞后 3 个月）	对近期日期使用最近可用年份回退
NASA POWER API 限流	使用多线程 + 本地缓存，减少重复请求
部分特征维度无显著贡献	通过消融实验提前排除，避免无效开发（如确有必要，放弃 OSM/RGB 等辅助维度）
团队协作效率	使用 Git 管理代码，明确模块接口，每周同步进度

十、参考文献与数据来源

[1] World Health Organization. *WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. 2021. <https://www.ncbi.nlm.nih.gov/books/NBK574591/>

[2] 中华人民共和国生态环境部. 《对十三届全国人大三次会议第6307号建议的答复》. 2020. https://www.mee.gov.cn/xxgk2018/xxgk/xxgk13/202012/t20201201_810823.html

[3] Holloway, T., et al. *Satellite Monitoring for Air Quality and Health*. NASA Technical Reports Server, 2023. https://ntrs.nasa.gov/api/citations/20230000905/downloads/Holloway_review_satellite%20monitoring%20for%20air%20quality%20and%20health.pdf

[4] Copernicus Atmosphere Monitoring Service / ECMWF. *CAMS global reanalysis (EAC4)*. <https://ads.atmosphere.copernicus.eu/datasets/cams-global-reanalysis-eac4>

[5] NASA POWER Project. *Daily API Documentation*. <https://power.larc.nasa.gov/docs/services/api/temportal/daily/>

[6] Xin, J., et al. *The observation-based relationships between PM2.5 and AOD over China*. Journal of Geophysical Research: Atmospheres, 2016. <https://doi.org/10.1002/2015JD024655>

[7] Zheng, Y., et al. *Analysis of influential factors for the relationship between PM2.5 and AOD in Beijing*. Atmospheric Chemistry and Physics, 2017. <https://acp.copernicus.org/articles/17/13473/2017/>

[8] Wei, J., Huang, W., Li, Z., Xue, W., Peng, Y., Sun, L., & Cribb, M. *Estimating 1-km-resolution PM2.5 concentrations across China using the space-time random forest approach*. Remote Sensing of Environment, 2019. <https://doi.org/10.1016/j.rse.2019.111221>

[9] Li, L., et al. *Mining Public Datasets for Modeling Intra-City PM2.5 Concentrations at a Fine Spatial Resolution*. Proceedings of the ACM SIGKDD International Workshop on Urban Computing, 2017. <https://pmc.ncbi.nlm.nih.gov/articles/PMC5841919/>